

ATP Tennis Match Outcome Prediction Using PySpark and Machine Learning

Alexandra Moldovan

June 2026

Contents

1	Introducere	3
2	Descrierea setului de date si preprocesarea datelor	3
2.1	Selectarea atributelor relevante	3
2.2	Curățarea datelor	5
2.3	Construirea setului de date pentru clasificare	5
3	Feature Engineering	5
3.1	Diferența de clasament ATP	6
3.2	Diferența de puncte ATP	6
3.3	Diferența de vârstă	6
3.4	Diferența de înălțime	6
3.5	Caracteristici categorice	7
3.6	Caracteristica Head-to-Head	7
4	Modele de Machine Learning utilizate	7
4.1	Logistic Regression	7
4.2	Random Forest	8
4.3	Gradient Boosted Trees	8
4.4	Strategia de evaluare	9
5	Rezultate experimentale	9
5.1	Compararea modelelor	9
5.2	Curba ROC	10
5.3	Analiza curbei ROC	10
5.4	Matricea de confuzie	11
5.5	Importanța caracteristicilor	11
5.6	Validare incrucisata	12
5.7	Predicția meciurilor viitoare	12
6	Limitări și probleme întâmpinate	13
7	Concluzii	14

1 Introducere

Tenisul profesionist reprezintă un domeniu în care analiza datelor poate fi utilizată pentru estimarea probabilității de victorie a unui jucător înainte de disputarea unui meci. Clasamentele ATP, punctele ATP, suprafața de joc, categoria turneului și caracteristicile jucătorilor oferă informații valoroase despre nivelul de performanță al acestora.

Scopul acestui proiect este dezvoltarea unui sistem de învățare automată capabil să prezică rezultatul meciurilor ATP utilizând date istorice și framework-ul PySpark. Proiectul urmărește un flux complet de analiză a datelor, incluzând preprocesarea datelor, construirea caracteristicilor relevante, antrenarea modelelor, evaluarea și compararea performanței acestora.

Pentru construirea modelelor predictive a fost utilizat un set de date ce conține meciuri ATP istorice. Datele au fost procesate și transformate într-un format adecvat unei probleme de clasificare binară. Au fost extrase mai multe caracteristici predictive, precum diferența de clasament ATP, diferența de puncte ATP, diferența de vârstă, diferența de înălțime, suprafața de joc, nivelul turneului și formatul meciului.

În cadrul proiectului au fost antrenați și evaluați trei algoritmi de Machine Learning disponibili în biblioteca PySpark MLlib: Logistic Regression, Random Forest și Gradient Boosted Trees (GBT). Performanța acestora a fost comparată utilizând metrici standard de clasificare precum Accuracy, Precision, Recall, F1 Score și ROC AUC.

De asemenea, a fost investigată și o caracteristică experimentală de tip Head-to-Head (H2H), care descrie istoricul confruntărilor directe dintre doi jucători, pentru a determina dacă aceasta poate îmbunătăți performanța predictivă a modelelor.

Rezultatul final al proiectului constă într-un pipeline reproductibil de Machine Learning capabil să estimeze probabilitatea de victorie a unui jucător folosind exclusiv informațiile disponibile înaintea disputării unui meci.

2 Descrierea setului de date si preprocesarea datelor

Pentru realizarea acestui proiect a fost utilizat un set de date ce conține meciuri istorice ATP. Fiecare înregistrare descrie un meci de tenis și include informații despre câștigător, învins, clasamente ATP, puncte ATP, vârstă, înălțime, suprafața de joc și caracteristicile turneului.

Datele au fost încărcate și procesate utilizând framework-ul PySpark, care permite manipularea eficientă a volumelor mari de date prin intermediul procesării distribuite.

2.1 Selectarea atributelor relevante

Din setul de date original au fost selectate doar coloanele considerate relevante pentru procesul de predicție:

```
df_model.printSchema()

root
|-- tourney_date: integer (nullable = true)
|-- surface: string (nullable = true)
|-- draw_size: integer (nullable = true)
|-- tourney_level: string (nullable = true)
|-- best_of: integer (nullable = true)
|-- player_1_id: integer (nullable = true)
|-- player_1_hand: string (nullable = true)
|-- player_1_ht: integer (nullable = true)
|-- player_1_age: double (nullable = true)
|-- player_1_rank: integer (nullable = true)
|-- player_1_rank_points: integer (nullable = true)
|-- player_2_id: integer (nullable = true)
|-- player_2_hand: string (nullable = true)
|-- player_2_ht: integer (nullable = true)
|-- player_2_age: double (nullable = true)
|-- player_2_rank: integer (nullable = true)
|-- player_2_rank_points: integer (nullable = true)
|-- label: integer (nullable = false)
```

Figure 1: Transformation of the original ATP dataset into a Player 1 vs Player 2 representation.

- tourney_date
- surface
- tourney_level
- best_of
- winner_id
- winner_rank
- winner_rank_points
- winner_age
- winner_ht
- loser_id
- loser_rank
- loser_rank_points
- loser_age
- loser_ht

Aceste atribute oferă informații despre nivelul de performanță al jucătorilor și contextul în care s-a disputat meciul. Setul de date ATP original stochează informațiile despre meciuri utilizând atribute specifice câștigătorului (**winner**) și învinsului (**loser**). O astfel de reprezentare nu poate fi utilizată direct pentru construirea unui model predictiv, deoarece rezultatul meciului este deja inclus implicit în denumirea atributelor, ceea ce ar conduce la fenomenul de *data leakage*.

Pentru a evita această problemă, setul de date a fost transformat într-o reprezentare neutră de tip *Player 1 versus Player 2*. Pentru fiecare meci, caracteristicile celor doi jucători au fost mapate în coloane generice, precum `player_1_rank` și `player_2_rank`, iar rezultatul meciului a fost stocat separat într-o variabilă țintă denumită `label`. Valoarea 1 indică faptul că `player_1` a câștigat meciul, în timp ce valoarea 0 indică faptul că `player_1` a pierdut.

Această transformare permite modelelor de Machine Learning să învețe relațiile dintre caracteristicile jucătorilor și rezultatul meciului, fără a avea acces direct la informații care ar dezvălui câștigătorul. Astfel, procesul de antrenare reflectă mai fidel un scenariu real de predicție, în care rezultatul meciului nu este cunoscut în momentul efectuării estimării.

2.2 Curățarea datelor

Înainte de construirea modelelor au fost eliminate înregistrările care conțineau valori lipsă pentru a evita apariția erorilor în procesul de antrenare. De asemenea, au fost păstrate doar observațiile pentru care informațiile esențiale erau disponibile.

Procesul de curățare a avut ca scop obținerea unui set de date consistent și complet, capabil să furnizeze informații relevante pentru modelele de Machine Learning.

2.3 Construirea setului de date pentru clasificare

Problema a fost formulată ca o problemă de clasificare binară. Pentru fiecare meci au fost generate două observații:

1. Câștigătorul a fost plasat în poziția `player_1`, iar eticheta a fost setată la valoarea 1.
2. Învinsul a fost plasat în poziția `player_1`, iar eticheta a fost setată la valoarea 0.

Prin această transformare s-a obținut un set de date echilibrat, în care fiecare clasă are aproximativ același număr de exemple.

Variabila țintă utilizată în procesul de clasificare este:

$$label = \begin{cases} 1, & \text{dacă player_1 câștigă meciul} \\ 0, & \text{dacă player_1 pierde meciul} \end{cases}$$

După transformare, setul final de date conține aproximativ 91.000 observații utilizate pentru antrenarea și evaluarea modelelor predictive.

3 Feature Engineering

Performanța unui model de Machine Learning depinde în mare măsură de calitatea caracteristicilor utilizate în procesul de antrenare. Din acest motiv,

după etapa de preprocesare a datelor au fost construite mai multe caracteristici derivate care descriu diferențele dintre cei doi jucători implicați într-un meci.

În loc să fie utilizate valorile absolute ale clasamentului, punctelor ATP sau caracteristicilor fizice, au fost calculate diferențe între cei doi jucători. Această abordare permite modelului să surprindă avantajul relativ al unui jucător față de adversarul său.

3.1 Diferența de clasament ATP

Prima caracteristică construită este diferența dintre pozițiile ATP ale celor doi jucători:

$$rank_diff = player_1_rank - player_2_rank$$

Clasamentul ATP reprezintă unul dintre cei mai importanți indicatori ai nivelului de performanță al unui jucător. Un clasament mai bun sugerează, în general, rezultate mai bune obținute în competițiile anterioare.

3.2 Diferența de puncte ATP

A doua caracteristică este diferența dintre punctele ATP acumulate de cei doi jucători:

$$rank_points_diff = player_1_rank_points - player_2_rank_points$$

Această caracteristică oferă o măsură mai detaliată a diferenței de valoare dintre jucători, deoarece doi sportivi pot ocupa poziții apropiate în clasament, dar pot avea diferențe semnificative de punctaj.

3.3 Diferența de vârstă

Pentru a surprinde influența experienței și a condiției fizice asupra performanței sportive, a fost calculată și diferența de vârstă:

$$age_diff = player_1_age - player_2_age$$

Această caracteristică permite modelului să identifice eventuale relații între vârsta jucătorilor și probabilitatea de victorie.

3.4 Diferența de înălțime

Înălțimea poate influența anumite aspecte ale jocului de tenis, precum serviciul și acoperirea terenului. Din acest motiv a fost construită caracteristica:

$$height_diff = player_1_ht - player_2_ht$$

3.5 Caracteristici categorice

Pe lângă caracteristicile numerice, au fost utilizate și variabile categorice care descriu contextul meciului:

- suprafața de joc (`surface`);
- nivelul turneului (`tourney_level`);
- mâna dominantă a jucătorilor;
- formatul meciului (`best_of`).

Aceste variabile au fost transformate în reprezentări numerice utilizând mecanismele de indexare oferite de biblioteca PySpark MLlib.

3.6 Caracteristica Head-to-Head

În cadrul proiectului a fost investigată și o caracteristică experimentală de tip Head-to-Head (H2H), care descrie istoricul confruntărilor directe dintre doi jucători.

Pentru fiecare meci a fost calculată proporția victoriilor obținute anterior de `player_1` împotriva lui `player_2`:

$$H2H = \frac{\text{victorii player_1}}{\text{total meciuri directe}}$$

Pentru a evita fenomenul de *data leakage*, au fost utilizate exclusiv meciurile disputate înainte de data meciului analizat.

Caracteristica H2H a fost evaluată experimental și comparată cu modelul de bază pentru a determina impactul acesteia asupra performanței predictive.

4 Modele de Machine Learning utilizate

După finalizarea etapelor de preprocesare și construire a caracteristicilor, au fost antrenate și evaluate mai multe modele de Machine Learning pentru predicția rezultatului meciurilor ATP.

Scopul acestei etape a fost identificarea modelului care oferă cea mai bună capacitate de generalizare și cele mai bune performanțe predictive asupra datelor nevăzute anterior.

4.1 Logistic Regression

Logistic Regression reprezintă unul dintre cele mai utilizate modele pentru probleme de clasificare binară. Acesta estimează probabilitatea apartenenței unei observații la una dintre cele două clase utilizând funcția logistică.

În cadrul proiectului, Logistic Regression a fost utilizat ca model de referință datorită simplității și interpretabilității sale. Modelul permite estimarea probabilității

ca `player_1` să câștige meciul pe baza caracteristicilor disponibile înaintea disputării acestuia.

Avantajele principale ale modelului sunt:

- implementare eficientă;
- timp redus de antrenare;
- interpretabilitate ridicată;
- capacitatea de a produce probabilități de clasificare.

4.2 Random Forest

Random Forest este un algoritm de tip ensemble care construiește un număr mare de arbori de decizie și combină predicțiile acestora prin vot majoritar.

Ideea principală constă în reducerea riscului de supraînvățare (*overfitting*) asociat arborilor individuali și îmbunătățirea capacității de generalizare.

Avantajele Random Forest includ:

- capacitatea de a modela relații neliniare;
- robustețe la zgomotul din date;
- estimarea importanței caracteristicilor;
- performanțe bune pe seturi de date complexe.

În cadrul proiectului, Random Forest a fost utilizat atât pentru predicție, cât și pentru analiza importanței caracteristicilor.

4.3 Gradient Boosted Trees

Gradient Boosted Trees (GBT) reprezintă o metodă avansată de tip boosting care construiește arborii secvențial, fiecare arbore nou încercând să corecteze erorile modelului anterior.

Spre deosebire de Random Forest, unde arborii sunt independenți, în GBT fiecare arbore este construit pe baza greșelilor făcute de ansamblul existent.

Principalele avantaje sunt:

- capacitatea de a surprinde relații complexe între caracteristici;
- performanțe predictive ridicate;
- adaptabilitate la probleme dificile de clasificare.

Dezavantajul principal îl reprezintă timpul mai mare de antrenare comparativ cu Logistic Regression și Random Forest.

	Model	AUC	Accuracy
0	Logistic Regression	0.718109	0.655447
1	Random Forest	0.716705	0.654531
2	GBT	0.716979	0.652413
3	Logistic Regression + H2H	0.714325	0.653124

Figure 2: Compararea performanțelor modelelor utilizând metricile ROC AUC și Accuracy.

4.4 Strategia de evaluare

Pentru toate modelele a fost utilizată aceeași împărțire a datelor în set de antrenare și set de testare, folosind o proporție de 80% pentru antrenare și 20% pentru testare.

Performanța modelelor a fost evaluată utilizând mai multe metrici specifice problemelor de clasificare:

- Accuracy;
- Precision;
- Recall;
- F1 Score;
- ROC AUC.

În plus, pentru modelul Logistic Regression a fost aplicată și validarea încrucișată (*Cross Validation*) pentru a verifica stabilitatea performanțelor obținute și pentru a reduce riscul ca rezultatele să fie influențate de o împărțire favorabilă a datelor.

5 Rezultate experimentale

5.1 Compararea modelelor

Tabelul din Figura 2 prezintă performanțele celor patru variante analizate în cadrul proiectului.

Modelul Logistic Regression a obținut cele mai bune rezultate, atingând o valoare ROC AUC de 0.718 și o acuratețe de aproximativ 65.5%. Acest rezultat indică faptul că modelul reușește să distingă în mod eficient între victoriile și înfrângerile jucătorului analizat.

Modelul Random Forest a obținut performanțe foarte apropiate, cu un ROC AUC de 0.717 și o acuratețe de 65.4%, demonstrând capacitatea arborilor de decizie de a surprinde relații neliniare între caracteristici.




Figure 3: Curba ROC obținută pentru modelul Logistic Regression.

Gradient Boosted Trees (GBT) a prezentat rezultate similare, obținând un ROC AUC de 0.717 și o acuratețe de aproximativ 65.2%. Diferențele reduse dintre modele sugerează că informațiile disponibile în setul de date sunt suficient de bine reprezentate și de modelul liniar Logistic Regression.

De asemenea, a fost evaluată o versiune extinsă a modelului Logistic Regression care include caracteristica Head-to-Head (H2H). Rezultatele au arătat o ușoară scădere a performanței, ROC AUC reducându-se la 0.714. Acest lucru indică faptul că istoricul confruntărilor directe dintre jucători nu a adus informații predictive suplimentare semnificative pentru setul de date utilizat.

Pe baza rezultatelor obținute, modelul Logistic Regression a fost selectat drept modelul final al proiectului datorită performanței ușor superioare și complexității reduse comparativ cu celelalte metode evaluate.

5.2 Curba ROC

Pentru evaluarea capacității de clasificare a modelului Logistic Regression a fost utilizată curba ROC (Receiver Operating Characteristic), prezentată în Figura 3.

5.3 Analiza curbei ROC

Curba ROC reprezintă relația dintre rata adevăratelor exemple pozitive (True Positive Rate) și rata exemplelor fals pozitive (False Positive Rate) pentru diferite praguri de clasificare.

Se poate observa că modelul se situează semnificativ deasupra diagonalei care reprezintă clasificarea aleatoare. Acest lucru indică faptul că modelul reușește să distingă între cele două clase mai bine decât o alegere realizată la întâmplare.

Valoarea ariei de sub curbă (AUC) obținută este aproximativ 0.718. În contextul problemelor de clasificare binară, o valoare AUC mai mare de 0.7 este considerată satisfăcătoare și indică o capacitate bună de discriminare între observațiile pozitive și cele negative.

Rezultatul obținut confirmă faptul că informațiile extrase din clasamentele

ATP, punctele ATP și celelalte caracteristici utilizate conțin informație predictivă relevantă pentru estimarea rezultatului unui meci de tenis.

5.4 Matricea de confuzie

Pentru o analiză mai detaliată a performanței modelului Logistic Regression a fost utilizată matricea de confuzie prezentată în Figura 4. Matricea de confuzie evidențiază numărul predicțiilor corecte și incorecte realizate de model pentru fiecare clasă. Se observă că modelul a clasificat corect 5755 de situații în care **player_1** a pierdut meciul și 5695 de situații în care **player_1** a câștigat. În același timp, au fost identificate 3099 cazuri în care modelul a prezis o victorie deși rezultatul real a fost o înfrângere și 2920 cazuri în care modelul a prezis o înfrângere deși rezultatul real a fost o victorie.




Figure 4: Matricea de confuzie obținută pentru modelul Logistic Regression.

Distribuția relativ echilibrată a erorilor indică faptul că modelul nu favorizează în mod excesiv una dintre clase și reușește să generalizeze corespunzător asupra datelor de test. Rezultatele confirmă performanța observată anterior prin metricile Accuracy și ROC AUC și demonstrează că modelul este capabil să identifice corect majoritatea rezultatelor meciurilor din setul de testare.

5.5 Importanța caracteristicilor

Un avantaj important al modelului Random Forest este capacitatea de a estima importanța fiecărei caracteristici utilizate în procesul de predicție. Figura 5 prezintă contribuția relativă a fiecărei caracteristici la deciziile luate de model.

Se observă că cele mai importante două caracteristici sunt **rank_points_diff** și **rank_diff**, care împreună contribuie cu peste 90% din importanța totală a modelului. Acest rezultat confirmă faptul că poziția în clasamentul ATP și numărul de puncte ATP reprezintă cei mai puternici predictorii ai rezultatului unui meci.

Caracteristicile **height_diff** și **age_diff** au avut o contribuție semnificativ mai redusă, sugerând că diferențele fizice dintre jucători influențează rezultatul într-o măsură mai mică decât nivelul sportiv reflectat de clasament.




Figure 5: Importanța caracteristicilor determinată de modelul Random Forest.

Variabilele care descriu contextul meciului, precum **surface**, **best_of** și **tourney_level**, au avut o importanță redusă în comparație cu caracteristicile asociate clasamentului ATP.

Rezultatele obținute sunt în concordanță cu realitatea competițională din tenisul profesionist, unde diferențele de clasament și punctaj ATP reprezintă indicatori puternici ai nivelului de performanță al unui jucător și ai probabilității sale de victorie.

5.6 Validare încrucișată

Pentru a verifica stabilitatea modelului și pentru a reduce influența unei împărțiri favorabile a datelor, a fost aplicată validarea încrucișată (*Cross Validation*) cu 3 fold-uri asupra modelului Logistic Regression.

Rezultatele obținute în urma validării încrucișate au fost:

- ROC AUC = 0.7177
- Accuracy = 0.6545

Aceste valori sunt foarte apropiate de rezultatele obținute în evaluarea inițială pe setul de test, unde modelul a înregistrat un ROC AUC de aproximativ 0.718 și o acuratețe de aproximativ 65.5%.

Diferențele reduse dintre cele două evaluări indică faptul că modelul prezintă o bună capacitate de generalizare și nu depinde de o anumită împărțire a datelor. Astfel, rezultatele obținute pot fi considerate stabile și reprezentative pentru performanța reală a modelului.

Validarea încrucișată confirmă că modelul Logistic Regression reprezintă o alegere adecvată pentru problema de predicție a rezultatelor meciurilor ATP utilizând caracteristicile disponibile în setul de date.

5.7 Predicția meciurilor viitoare

După antrenarea și evaluarea modelelor de Machine Learning, a fost implementată o funcție care permite estimarea rezultatului unui meci ATP viitor între doi jucători.

Funcția primește ca parametri numele celor doi jucători, suprafața de joc, nivelul turneului și formatul meciului. Pe baza statisticilor istorice disponibile în setul de date sunt extrase informațiile relevante pentru fiecare jucător, iar ulterior sunt calculate diferențele utilizate de model, precum diferența de clasament ATP, diferența de puncte ATP, diferența de vârstă și diferența de înălțime.

Caracteristicile calculate sunt introduse în modelul Logistic Regression antrenat anterior, care generează probabilitatea de victorie pentru fiecare dintre cei doi jucători. În funcție de probabilitatea estimată, sistemul indică jucătorul favorit.

Această funcționalitate demonstrează aplicabilitatea practică a modelului dezvoltat și permite utilizarea sa pentru analiza unor confruntări viitoare folosind exclusiv informații disponibile înaintea disputării meciului.



```
[120]: predict_match
       "Novak Djokovic",
       "Carlos Alcaraz",
       "Hard",
       "tournament",
       test_atp50
       }
```

Match prediction
Novak Djokovic: 87.44%
Carlos Alcaraz: 12.56%
Predicted winner: Novak Djokovic

```
[122]: predict_match
       "Ruger Federer",
       "Novak Djokovic",
       "Clay",
       "tournament",
       test_atp50
       }
```

Match prediction
Ruger Federer: 31.11%
Novak Djokovic: 68.89%
Predicted winner: Novak Djokovic

```
[133]: predict_match
       "Ruger Federer",
       "Alexander Zverev",
       "Clay",
       "tournament",
       test_atp50
       }
```

Match prediction
Ruger Federer: 73.27%
Alexander Zverev: 26.73%
Predicted winner: Ruger Federer

Figure 6: Exemple de predicții generate pentru meciuri ATP utilizând modelul Logistic Regression.

În exemplele prezentate, modelul estimează probabilitățile de victorie pentru mai multe confruntări dintre jucători de top. Rezultatele arată că modelul este capabil să diferențieze între meciuri echilibrate și meciuri în care unul dintre jucători pornește cu un avantaj evident pe baza caracteristicilor istorice disponibile

Deși modelul nu poate anticipa factori neprevăzuți precum accidentările, starea fizică din ziua meciului sau condițiile meteorologice, acesta oferă o estimare obiectivă bazată pe informațiile istorice disponibile și poate fi utilizat ca instrument de suport în analiza meciurilor de tenis.

6 Limitări și probleme întâmpinate

În timpul dezvoltării proiectului au fost investigate mai multe caracteristici pentru îmbunătățirea performanței modelelor predictive. Printre acestea se numără Fatigue Score, Surface Win Rate, Win Streak și Head-to-Head.

Pentru integrarea simultană a tuturor caracteristicilor istorice a fost construit un set de date extins (`df_enriched`) utilizând mai multe operații de tip Window Function și Join asupra întregului istoric ATP. Din cauza dimensiunii setului de date și a numărului mare de operații distribuite, procesul a generat un consum ridicat de memorie și timp de execuție.

În consecință, pentru a menține stabilitatea execuției și pentru a evita erorile de tip OutOfMemory, a fost aleasă o variantă optimizată a pipeline-ului. Dintre caracteristicile avansate, a fost integrată și evaluată complet caracteristica Head-to-Head (H2H), care utilizează istoricul întâlnirilor directe dintre doi jucători.

7 Concluzii

În cadrul acestui proiect a fost dezvoltat un sistem de predicție a rezultatelor meciurilor ATP utilizând PySpark și algoritmi de Machine Learning. Pornind de la date istorice ATP, a fost construit un flux complet de analiză care a inclus preprocesarea datelor, transformarea setului de date într-o reprezentare de tip Player 1 versus Player 2, generarea caracteristicilor relevante, antrenarea modelelor și evaluarea performanței acestora.

Au fost comparate trei modele de clasificare: Logistic Regression, Random Forest și Gradient Boosted Trees. Rezultatele obținute au arătat că toate modelele au oferit performanțe similare, cu valori ROC AUC de aproximativ 0.71 și o acuratețe de aproximativ 65

Analiza importanței caracteristicilor a evidențiat faptul că diferența de puncte ATP și diferența de clasament ATP reprezintă cei mai puternici predictorii ai rezultatului unui meci. Acest rezultat confirmă faptul că nivelul general de performanță al jucătorilor este principalul factor care influențează probabilitatea de victorie.

Pe lângă caracteristicile de bază, au fost implementate și caracteristici avansate inspirate din analiza sportivă reală, precum Fatigue Score, Win Streak, Surface Win Rate și Head-to-Head. Aceste caracteristici au permis modelului să utilizeze informații istorice suplimentare despre forma și performanța recentă a jucătorilor.

Un rezultat important al proiectului este dezvoltarea unei funcții capabile să estimeze probabilitatea de victorie pentru două persoane selectate de utilizator. Această funcționalitate transformă modelul într-un instrument practic care poate fi utilizat pentru analiza unor confruntări viitoare și demonstrează aplicabilitatea concretă a soluției dezvoltate.

Validarea încrucișată a confirmat stabilitatea modelului, iar valorile obținute au fost apropiate de cele calculate pe setul de test, indicând o capacitate bună de generalizare și un risc redus de supraînvățare.

În viitor, proiectul poate fi extins prin integrarea unor caracteristici suplimentare precum statistici detaliate de serviciu, rezultate recente pe categorii de turnee, istoricul accidentărilor, condițiile meteorologice sau informații despre avantajul terenului propriu.

Declarație privind utilizarea Inteligenței Artificiale

Am utilizat ChatGPT pentru clarificarea unor concepte, generarea de sugestii tehnice și asistență în redactarea raportului. Rezultatele au fost verificate prin

implementare și testare practică. Experimentele, analiza rezultatelor și interpretarea finală îmi aparțin și pot explica fiecare etapă principală a proiectului.